Tarea 3: Introducción a Series de Tiempo

Sofía Isabela Sandoval Vásquez
Análisis y Ciencia de Datos
Facultad de Ingeniería, Universidad del Istmo de Guatemala

19 de octubre de 2026

Resumen

La primera mitad del trabajo simula procesos cuya respuesta se conoce: un AR(1) con cuatro valores de ϕ y dos procesos sin memoria pero con media cambiante. Con 5 000 réplicas de cada uno se ve que la prueba de retardo 1 reprueba a una tendencia que no tiene memoria y no detecta, en la gran mayoría de las réplicas, un patrón semanal que sí tiene estructura, igual que le pasó a RANDU en la Tarea 2, mientras que Ljung–Box con $m = 10$ sí lo detecta. La segunda mitad trabaja con las 541,909 líneas de factura de Online Retail. Se documentan cinco reglas de limpieza en una bitácora, se reconstruye el calendario de la tienda (cierra los sábados y en los bank holidays, incluida la boda real de 2011) y se hace una descomposición clásica con media móvil e índices estacionales. La ACF de la serie tiene su pico en el rezago 6, que es una semana de días abiertos. Después se pasa del AR(1) a dos SARIMA con $s = 6$, y sólo el modelo con diferencias (S2) deja residuos de ruido blanco. En el pronóstico con origen móvil semanal, S2 gana en prueba con un MAE de £12,545, pero todas las estimaciones hechas dentro del entrenamiento se quedan cortas, porque la serie casi duplicó su nivel en la temporada navideña. El trabajo cierra con un análisis RFM: los campeones son el 21.5 % de los clientes y generan el 53.3 % de la venta de octubre a diciembre, y los clientes nuevos aportan un 15.7 % que un modelo construido sólo con los clientes existentes no puede ver.

Índice

1. Introducción **4**

2. Apoyo de inteligencia artificial **4**

3. Parte 0: Procesos simulados **5**
3.1. Derivaciones a mano (0.1) . . . 5
3.2. Simulación (0.2) . . . 6
3.3. Lectura de la tabla (0.3) . . . 7
3.4. Las dos razones para reprobar (0.4) . . . 7
3.5. La prueba que sí ve (0.5) . . . 9

4. Los datos y la Parte 1: Limpieza **10**
4.1. Carga y tamaño (1.1) . . . 10
4.2. Los casos sospechosos (1.2) . . . 10
4.3. Bitácora de limpieza (1.3) . . . 12
4.4. Las seis líneas más grandes (1.4) . . . 12
4.5. La función `limpiar` (1.5) . . . 13

5. Parte 2: El calendario **14**
5.1. La serie diaria (2.1) . . . 14
5.2. Los días sin transacciones (2.2) . . . 14
5.3. ¿Cero o faltante? (2.3) . . . 14
5.4. El último día (2.4) . . . 15

6. Parte 3: Tendencia, estacionalidad y autocorrelación **16**
6.1. Tendencia (3.1) . . . 16
6.2. Estacionalidad (3.2) . . . 17
6.3. Autocorrelación (3.3) . . . 17

7. Parte 4: Del AR(1) al SARIMA **19**
7.1. Indicadoras de día de la semana (4.1) . . . 19
7.2. AR(1) sobre los residuos (4.2) . . . 20
7.3. SARIMA (4.3) . . . 20
7.4. Diagnóstico (4.4) . . . 21
7.5. ¿Hacia dónde van los pronósticos? (4.5) . . . 21

8. Parte 5: Pronóstico y fuga **22**
8.1. Los seis modelos (5.1) . . . 22
8.2. Tres formas de estimar el error (5.2) . . . 23
8.3. ¿Qué modelo gana en prueba? (5.3) . . . 24
8.4. La trampa (5.4) . . . 24
8.5. ¿Por qué todo se queda corto? (5.5) . . . 25

9. Parte 6: Detrás de la serie hay clientes: análisis RFM **26**
9.1. R, F y M al 1 de octubre (6.1) . . . 26
9.2. Puntajes por quintiles (6.2) . . . 26
9.3. ¿Quién vuelve a comprar? (6.3) . . . 27
9.4. Los campeones (6.4) . . . 27

9.5. Los clientes nuevos (6.5) 28

10.Conclusiones **29**

1. Introducción

En las tareas anteriores casi todos los datos eran intercambiables: se podían barajar las filas y nada cambiaba. En una serie de tiempo eso ya no es cierto, porque el orden es justamente la información. Lo que se vendió ayer dice algo de lo que se va a vender hoy, los lunes no se parecen a los domingos, y el futuro no se puede usar para entrenar.

El trabajo está dividido en dos mitades. En la Parte 0 se construye el vocabulario con procesos simulados: como se conoce el proceso que generó los datos, se puede comprobar qué ve y qué no ve cada herramienta. La idea central es que una serie puede reprobar una prueba de independencia por dos razones muy distintas, porque tiene memoria o porque su media no es constante, y que distinguir una de la otra es la mitad del trabajo.

En las Partes 1 a 6 se aplica todo eso a datos reales: las transacciones de un año de una tienda en línea del Reino Unido que vende artículos de regalo, casi todo a mayoristas. Primero se limpian (Parte 1) y se reconstruye el calendario (Parte 2). Después se separa la tendencia y la estacionalidad semanal (Parte 3), se modela la memoria que queda con un AR(1) y con dos modelos SARIMA (Parte 4), se compara el pronóstico de seis modelos con tres formas distintas de validar (Parte 5) y, al final, se mira a los clientes que hay detrás de la serie con un análisis RFM (Parte 6).

Todos los números, tablas y figuras de este documento los generan los scripts de `src/` a partir del archivo `Online Retail.xlsx` original, con las semillas que se documentan en el README.

2. Apoyo de inteligencia artificial

Para la elaboración de este trabajo se contó con el apoyo de una herramienta de inteligencia artificial. El proceso fue el siguiente.

Primero se hizo una lectura personal del enunciado y de las secciones recomendadas de los dos libros de referencia (FPP2 y Tsay), y se definió qué pedía cada inciso. Esas notas y las fuentes se le compartieron a la herramienta para que le sirvieran de base.

Para el código se le entregaron las semillas que debían usarse y las decisiones de limpieza que se habían tomado al revisar los datos. Sobre esa base se le pidió apoyo para escribir las implementaciones y para darle un estilo propio a las gráficas.

Los resultados se analizaron de forma personal, y esos análisis se le entregaron en borrador para que ayudara a mejorar la redacción antes de incorporarlos al documento. También se le pidió ayuda con el código del documento en LaTeX.

Por último se hizo una revisión completa del documento para verificar que cada cifra coincidiera con lo que producen los scripts y para mejorar la estructura y las conclusiones.

3. Parte 0: Procesos simulados

3.1. Derivaciones a mano (0.1)

El modelo es $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{iid}{\sim} N(0, \sigma^2)$ y $|\phi| < 1$. Se usan dos hechos: si el proceso es estacionario, $\mathrm{E}[Y_t] = \mathrm{E}[Y_{t-1}]$ y $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1})$; y ε_t es independiente de todo el pasado, en particular de $Y_{t-1}, Y_{t-2}, \ldots$

Media

Tomando valor esperado en ambos lados,

$$\mathrm{E}[Y_t] = c + \phi\ \mathrm{E}[Y_{t-1}] + \mathrm{E}[\varepsilon_t] = c + \phi\ \mathrm{E}[Y_t] \quad \Longrightarrow \quad \mathrm{E}[Y_t]\,(1-\phi) = c \quad \Longrightarrow \quad \mathrm{E}[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $|\phi| < 1$ implica $\phi \neq 1$.

Varianza

La constante no aporta varianza y, como ε_t es independiente de Y_{t-1}, la covarianza entre ambos es cero:

$$\mathrm{Var}(Y_t) = \phi^2\,\mathrm{Var}(Y_{t-1}) + \mathrm{Var}(\varepsilon_t) = \phi^2\,\mathrm{Var}(Y_t) + \sigma^2 \quad \Longrightarrow \quad \mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}.$$

Aquí hace falta $|\phi| < 1$ para que $1 - \phi^2 > 0$ y la varianza sea positiva y finita.

Autocorrelación

Sea $\mu = c/(1-\phi)$ y $X_t = Y_t - \mu$. Restando $\mu = c + \phi\mu$ al modelo queda $X_t = \phi X_{t-1} + \varepsilon_t$. Para $k \geq 1$, multiplicando por X_{t-k} y tomando valor esperado,

$$\gamma_k = \mathrm{E}[X_t X_{t-k}] = \phi\ \mathrm{E}[X_{t-1} X_{t-k}] + \mathrm{E}[\varepsilon_t X_{t-k}] = \phi\,\gamma_{k-1} + 0,$$

porque X_{t-k} sólo depende de choques anteriores a t. Aplicando la recursión k veces, $\gamma_k = \phi^k \gamma_0$, y por lo tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria

Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, al desenrollar la recursión queda $Y_t = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$. Como los choques son independientes, las varianzas se suman:

$$\mathrm{Var}(Y_t) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i) = t\sigma^2.$$

La varianza depende de t y crece sin límite, así que no se cumple la condición $\mathrm{Var}(Y_t) = \sigma^2$ para todo t de la estacionariedad débil. Es también lo que hace que la derivación anterior no aplique: con $\phi = 1$ la fórmula $\sigma^2/(1-\phi^2)$ da una división entre cero. Intuitivamente, la caminata nunca olvida un choque, así que la incertidumbre se acumula.

3.2. Simulación (0.2)

Se programó una función que simula $n = 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$, arrancando en $Y_0 = 0$ y descartando los primeros 200 pasos para que el valor inicial no importe. Con $|\phi| < 1$ eso funciona porque el efecto de Y_0 decae como ϕ^{200}, que para $\phi = 0.9$ ya es del orden de 10^{-10}. Con $\phi = 1$ no funciona, porque la caminata nunca olvida: el valor en el paso 200 se arrastra para siempre. Sin embargo, eso no afecta a r_k, porque lo único que deja la quema es un nivel constante Y_{200} que se suma a toda la serie, y r_k resta la media muestral antes de calcular nada. Sumar una constante a toda la serie no cambia ni el numerador ni el denominador de r_k.

La figura 1 muestra una realización de cada escenario. Se ve cómo la memoria cambia el aspecto de la serie: con $\phi = 0$ no hay patrón, con $\phi = 0.5$ aparecen rachas cortas, con $\phi = 0.9$ la serie se queda varios pasos del mismo lado del cero, y la caminata aleatoria deambula sin volver a ningún nivel.

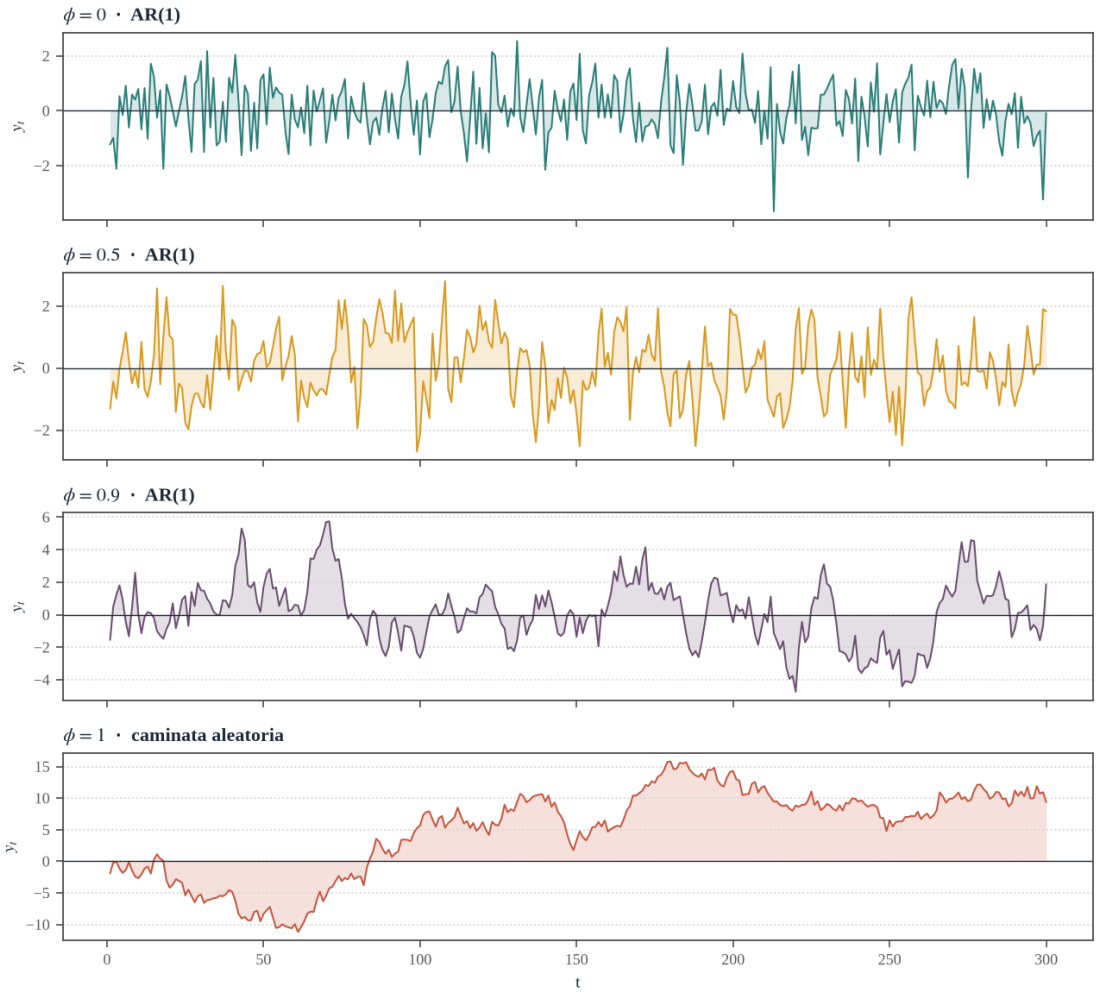


Figura 1: Una realización de 300 pasos para cada valor de ϕ.

Después se hicieron 5 000 réplicas de cada escenario, con una semilla distinta para cada ϕ (Tabla 1). Entre paréntesis va el error estándar de cada promedio, $s/\sqrt{5000}$ para las medias y $\sqrt{\hat{p}(1-\hat{p})/5000}$ para la tasa de rechazo, que es una proporción. La banda de la prueba es $1.96/\sqrt{300} = 0.1132$.

Tabla 1: AR(1) con 5 000 réplicas por escenario. Entre paréntesis, el error estándar del promedio.

ϕ	$\bar{r}_1$		$\bar{r}_5$		ϕ^5	Rechazo $\lvert r_1\rvert > 1.96/\sqrt{n}$		$\hat{\phi}_{\text{OLS}}$	
0	−0.0022	(0.0008)	−0.0030	(0.0008)	0.0000	0.0462	(0.0030)	−0.0022	(0.0008)
0.5	0.4897	(0.0007)	0.0212	(0.0010)	0.0312	1.0000	(0.0000)	0.4913	(0.0007)
0.9	0.8838	(0.0004)	0.5346	(0.0014)	0.5905	1.0000	(0.0000)	0.8870	(0.0004)
1	0.9753	(0.0002)	0.8811	(0.0009)	1.0000	1.0000	(0.0000)	0.9820	(0.0002)

3.3. Lectura de la tabla (0.3)

La tasa de rechazo con $\phi = 0$

Sale 0.0462, con un error estándar de 0.0030, así que es compatible con el 5 % que se esperaba: está a menos de dos errores estándar. Es lo que tiene que pasar, porque con ruido blanco $r_1 \approx N(0, 1/n)$ y la banda está puesta justamente para que el 5 % de las veces se salga por pura suerte. La pequeña diferencia hacia abajo se explica porque la aproximación normal es asintótica: con n finito, r_1 tiene un ligero sesgo negativo (su media es cerca de $-1/n$) y una varianza un poco menor que $1/n$.

La caminata aleatoria y r_5

La teoría diría $\phi^5 = 1$, pero el promedio de r_5 es apenas 0.881. La fórmula $\rho_k = \phi^k$ supone estacionariedad, y la caminata no lo es: no tiene una media fija alrededor de la cual oscilar. La media muestral $\bar{y}$ queda en algún punto del recorrido de esa realización, y r_k mide qué tanto se parecen los desvíos respecto a ese punto. Con una serie finita, esos desvíos se ven menos correlacionados a medida que k crece, aunque el proceso nunca olvide nada. En otras palabras, r_k estima algo que para la caminata no existe.

El sesgo del OLS

Sí hay sesgo, siempre hacia abajo, y crece con ϕ: para $\phi = 0.5$ el promedio es 0.4913, para $\phi = 0.9$ es 0.8870 y para la caminata 0.9820. Con errores estándar de cuatro diezmilésimas, las tres diferencias son claramente reales. Es el sesgo clásico de muestra finita del AR(1), que aproximadamente vale $-(1 + 3\phi)/n$: con $n = 300$ eso predice -0.008 y -0.012 para $\phi = 0.5$ y 0.9, muy cerca de lo que se observa.

Conviene precisar de dónde sale. En el AR(1) sí se cumple la exogeneidad contemporánea: ε_t es independiente de y_{t-1}, porque y_{t-1} sólo depende de choques anteriores. Eso basta para que el OLS sea consistente. Lo que no se cumple es la exogeneidad *estricta*, que es la que hace falta para que el OLS sea insesgado en muestras finitas: el error tiene que ser independiente de los regresores de *todas* las filas, y aquí ε_t forma parte de y_t, que es el regresor de la fila siguiente, y de $y_{t+1}, y_{t+2}, \ldots$ Como el estimador es un cociente que usa todos los regresores a la vez (y además la media muestral, que también contiene a ε_t), el numerador y el denominador quedan correlacionados y el valor esperado del cociente se aleja de ϕ. El sesgo baja como $1/n$, pero con 300 observaciones todavía se nota, y es más fuerte cerca de la raíz unitaria.

3.4. Las dos razones para reprobar (0.4)

Ahora se simulan procesos sin ninguna memoria, $Y_t = m_t + \varepsilon_t$, pero con media cambiante: una tendencia lineal $m_t = 2t/300$ y un patrón semanal donde el día t mód $7 = 6$ vale -1.5 y los demás 0.25. La Tabla 2 repite el ejercicio y agrega r_7, y la figura 2 muestra una realización y la ACF promedio de cada uno.

Tabla 2: Procesos sin memoria con media cambiante, 5 000 réplicas.

Proceso	$\bar{r}_1$		$\bar{r}_7$		Rechazo con r_1	
Ruido blanco ($\phi = 0$)	−0.0022	(0.0008)	−0.0028	(0.0008)	0.0462	(0.0030)
Tendencia lineal	0.2469	(0.0008)	0.2318	(0.0008)	0.9868	(0.0016)
Patrón semanal	−0.0469	(0.0007)	0.2651	(0.0008)	0.1082	(0.0044)

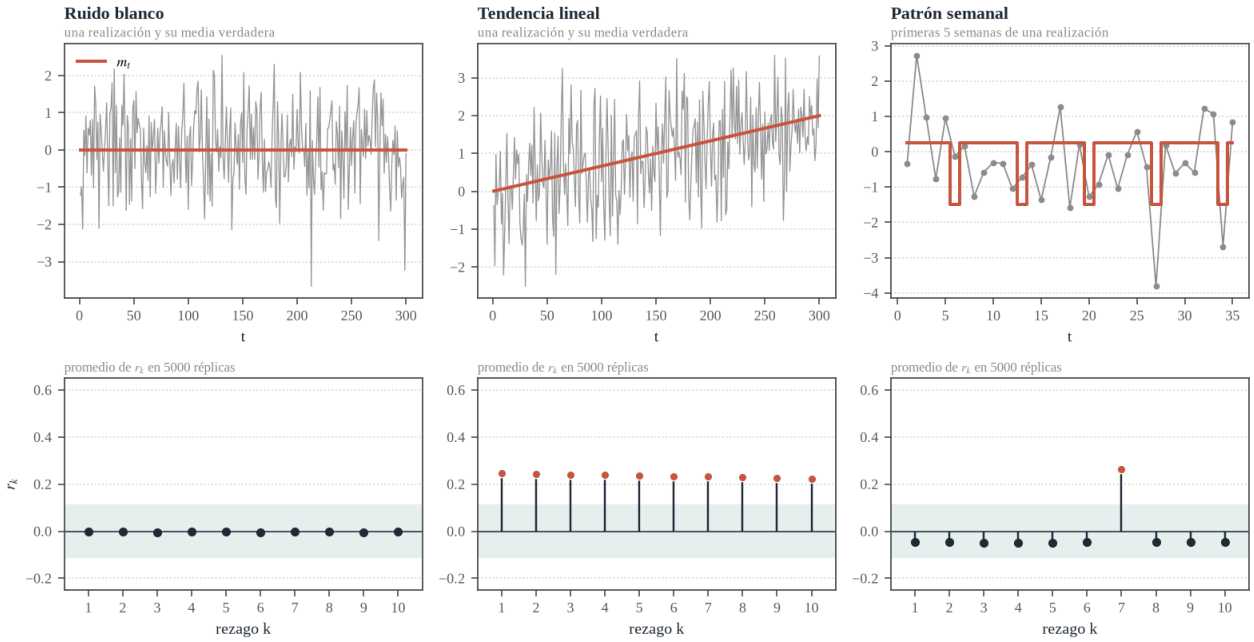


Figura 2: Arriba, una realización de cada proceso con su media verdadera. Abajo, el promedio de r_k en las 5 000 réplicas; los puntos terracota se salen de la banda.

La tendencia reprueba sin tener memoria. Rechaza en el 0.987 de las réplicas, con $\bar{r}_1 = 0.247$. Los días del final están todos por encima de $\bar{y}$ y los del principio todos por debajo, así que cada valor se parece a su vecino aunque los choques sean independientes. Su ACF es casi plana ($r_7 = 0.232$): baja muy despacio, que es la pista visual de la media no constante.

El patrón semanal casi nunca es detectado, aunque tenga estructura. La prueba rechaza en el 0.108 de las réplicas, así que no lo detecta en el 89 % de ellas. Esa tasa es algo mayor que el 5 % nominal porque r_1 tiene una media ligeramente negativa ($\bar{r}_1 = -0.047$): el día bajo queda junto a días normales y eso produce una pequeña correlación negativa en el rezago 1. Pero está muy lejos de detectar el patrón de forma confiable, porque toda la estructura está en el rezago 7 ($r_7 = 0.265$), que la prueba de retardo 1 no mira.

La conexión con RANDU es directa. En la Tarea 2, RANDU pasó la prueba de autocorrelación de retardo 1 sin problema, pero sus ternas consecutivas caían en 15 planos, porque cumple exactamente $x_{k+2} = 6x_{k+1} - 9x_k \pmod{2^{31}}$. En los dos casos la dependencia existe, pero vive en un rezago o en una combinación de rezagos que la prueba no está mirando. Una prueba que sólo ve un rezago sólo puede confirmar la ausencia de dependencia en ese rezago, nada más.

3.5. La prueba que sí ve (0.5)

Se implementó Ljung–Box a mano con la fórmula del enunciado y se comprobó contra la función `acorr_ljungbox` de statsmodels: sobre la misma serie, la implementación propia da $Q(10) = 33.6542$ y statsmodels da 33.6542, idénticos. La Tabla 3 compara las tasas de rechazo al 5 %. Como pide la sección teórica, se probaron los dos criterios para elegir m: $m = 10$ (FPP2 sin estacionalidad) y $m = 6 \approx \log 300$ (Tsay).

Tabla 3: Tasa de rechazo al 5 % de la prueba de retardo 1 y de Ljung–Box.

Proceso	Retardo 1		Ljung–Box $m = 6$		Ljung–Box $m = 10$	
Ruido blanco ($\phi = 0$)	0.0462	(0.0030)	0.0472	(0.0030)	0.0500	(0.0031)
Tendencia lineal	0.9868	(0.0016)	1.0000	(0.0000)	1.0000	(0.0000)
Patrón semanal	0.1082	(0.0044)	0.2118	(0.0058)	0.9522	(0.0030)

Con ruido blanco, Ljung–Box con $m = 10$ rechaza el 0.050 de las veces, que es exactamente el nivel nominal: no se vuelve más estricta con el proceso que sí cumple. Con la tendencia rechaza siempre, igual que la prueba de retardo 1. El cambio está en el patrón semanal: pasa de 0.108 a 0.952. Ljung–Box junta $r_1, \ldots, r_{10}$ en un solo estadístico, así que el r_7 grande entra en la suma y la prueba lo ve. Por la misma razón, con $m = 6$ sólo rechaza el 0.212: el rezago 7 queda fuera de la suma. Ésa es la lección práctica sobre cómo elegir m: tiene que cubrir el periodo estacional, y por eso FPP2 recomienda $m = 2s$ cuando hay estacionalidad. El criterio $m \approx \log n$ de Tsay funciona bien sin estacionalidad, pero aquí se queda corto.

4. Los datos y la Parte 1: Limpieza

4.1. Carga y tamaño (1.1)

Los datos son el archivo `Online Retail.xlsx` del repositorio de UCI. Al cargarlo, las columnas `InvoiceNo`, `StockCode` y `CustomerID` se leen como texto, por tres razones. `InvoiceNo` mezcla números (`536365`) con códigos que empiezan con letra (`C536379`), y leerlos como número rompe la columna o pierde el prefijo, que es justamente lo que dice si una factura es cancelación. `StockCode` también mezcla códigos numéricos (`71053`) con alfanuméricos (`85123A`, `POST`). Y `CustomerID`, como tiene celdas vacías, pandas lo lee como número decimal (`17850.0`), que es un identificador y no una cantidad: no tiene sentido sumarlo ni promediarlo, y el `.0` estorba al cruzar tablas.

El archivo tiene 541,909 filas, 25,900 facturas distintas, 4,070 códigos de producto y 4,372 clientes. El 24.9 % de las filas no tiene `CustomerID`.

4.2. Los casos sospechosos (1.2)

La Tabla 4 cuantifica cada caso sobre los datos crudos, cada uno por separado, y la Tabla 5 desglosa los códigos que no empiezan con cinco dígitos. La decisión para cada caso es la siguiente.

Tabla 4: Cada caso medido sobre los datos crudos, por separado (un mismo renglón puede estar en más de un caso). El monto es la suma de `Quantity` × `UnitPrice`.

Caso	Filas	Monto
Duplicadas exactas	5,268	£21,741
Prefijo C (cancelación)	9,288	−£896,812
Prefijo A (deuda incobrable)	3	−£11,062
StockCode sin cinco dígitos	2,995	−£44,562
de ellos, servicios eliminados	2,260	£39,783
de ellos, M y D (ajustes de precio)	649	−£74,368
Precio cero	2,515	£0
Precio negativo	2	−£22,124
Cantidad negativa sin C	1,336	£0
Sin CustomerID	135,080	£1,447,682

(a) Filas duplicadas exactas: se van

Hay 5 268 filas idénticas en todas las columnas, incluida la hora al minuto. Una misma factura no debería tener dos líneas iguales del mismo producto en el mismo minuto: es un registro doble del sistema. Se conserva la primera aparición.

(b) Facturas que no empiezan con un dígito

Hay dos prefijos. Las 9,288 líneas con `C` son cancelaciones: **se quedan**, con su cantidad negativa, para que resten el día en que ocurren, como pide el enunciado. Las 3 líneas con `A` son "Adjust bad debt": un ajuste contable por deuda incobrable, no una venta ni una devolución de mercancía. **Se van**.

Tabla 5: Códigos de `StockCode` que no empiezan con cinco dígitos.

Código	Descripción	Filas	Monto	Decisión
`POST`	POSTAGE	1,256	£66,231	se va
`DOT`	DOTCOM POSTAGE	710	£206,245	se va
`M`	Manual	571	−£68,674	ajuste, se queda
`C2`	CARRIAGE	144	£6,986	se va
`D`	Discount	77	−£5,696	ajuste, se queda
`S`	SAMPLES	63	−£3,049	se va
`DCGS…`	Productos varios (bolsas, collares, lámparas)	45	£398	producto, se queda
`BANK CHARGES`	Bank Charges	37	−£7,176	se va
`AMAZONFEE`	AMAZON FEE	34	−£221,520	se va
`gift_0001_…`	Gift vouchers de £10 a £50	34	£686	producto, se queda
`CRUK`	CRUK Commission	16	−£7,933	se va
`PADS`	PADS TO MATCH ALL CUSHIONS	4	£0	producto, se queda
`B`	Adjust bad debt	3	−£11,062	se va (prefijo A)
`m`	Manual	1	£3	ajuste, se queda

(c) Códigos que no son productos

La pista de la descripción separa tres grupos. Los cargos de envío (`POST`, `DOT`, `C2`), las comisiones y cargos bancarios (`AMAZONFEE`, `BANK CHARGES`, `CRUK`) y las muestras (`S`) **se van**: no son venta de mercancía, y algunos ni siquiera son ingresos (la comisión de Amazon resta £221 520 en apenas 34 líneas). Los `DCGS…`, los vales de regalo `gift_0001_…` y `PADS` **sí son productos** y se quedan. El caso intermedio es `M` (Manual) y `D` (Discount): no son productos, pero corrigen el precio de ventas reales. La mayoría de las líneas `M` grandes están en facturas `C`, y el caso más claro está en la sección 4.4: una venta capturada con un precio 60 veces mayor que se anula con una línea Manual. Si se quitaran las `M`, la venta mal capturada se quedaría sin su corrección. Por eso `M` y `D` **se quedan** como ajustes de la venta neta.

(d) Precios cero o negativos: se van

Con precio cero la línea no mueve dinero: son regalos, líneas de inventario o errores de captura, y no aportan nada a la venta. Los dos precios negativos son las líneas de deuda incobrable de (b).

(e) Cantidades negativas sin C: se van

Las 1,336 líneas tienen todas precio cero y ninguna tiene cliente. Sus descripciones son “check”, “damaged”, “thrown away”, “wet pallet”, “?”: son ajustes de inventario por mercancía dañada o perdida, no devoluciones de clientes. No mueven dinero.

(f) Filas sin `CustomerID`: se quedan para la serie

Son el 24.9 % de las filas y £1.45 millones de venta. Para la venta neta diaria lo que importa es cuánto se vendió, no quién compró, y quitarlas haría que la serie subestimara sistemáticamente la venta. En la Parte 6 la pregunta es distinta: un cliente sin identificador no tiene recencia ni frecuencia, así que ahí sí se filtran.

4.3. Bitácora de limpieza (1.3)

La Tabla 6 es la bitácora. Las reglas se aplican en el orden en que aparecen, y cada conteo es sobre lo que dejó la regla anterior.

Tabla 6: Bitácora de limpieza, en el orden en que se aplican las reglas.

Orden	Regla	Filas eliminadas	Monto eliminado
1	Filas duplicadas exactas (se conserva la primera)	5,268	£21,740.98
2	Facturas con prefijo A (ajuste de deuda incobrable)	3	−£11,062.06
3	Códigos que no son mercancía (envío, comisiones, muestras)	2,259	£39,792.90
4	Precio unitario cero o negativo	2,502	£0.00
5	Cantidad negativa en facturas que no son cancelación	0	£0.00
	Total eliminado	10,032	£50,471.82

El orden importa, y la regla 5 lo muestra: medida sobre los datos crudos elimina 1,336 filas, pero en la bitácora elimina cero, porque todas esas filas tienen precio cero y la regla 4 ya se las llevó. Lo mismo pasa con los duplicados: si la regla 1 fuera la última, algunos de ellos ya habrían caído por otra regla y su conteo sería menor. En total se eliminan 10,032 filas, el 1.9 % del archivo, y la venta neta pasa de £9,747,748 a £9,697,276. La limpieza mueve poco dinero en total, pero lo que quita está concentrado en pocos días, que es lo que importa para una serie diaria.

4.4. Las seis líneas más grandes (1.4)

La Tabla 7 muestra las seis líneas con mayor |Quantity × UnitPrice| antes de limpiar. Resultan ser tres pares, y en cada par una línea anula a la otra.

Tabla 7: Las seis líneas con mayor |Quantity × UnitPrice| antes de limpiar. "Neto" es la suma de todas las líneas limpias de ese cliente en ese día.

Factura	Fecha	Descripción	Cantidad	Precio	Monto	Cliente	¿Queda?	Neto del día
C581484	09/12/2011 09:27	PAPER CRAFT , LITTLE BIRDIE	−80,995	£2.08	−£168,469.60	16446	sí	£0.00
581483	09/12/2011 09:15	PAPER CRAFT , LITTLE BIRDIE	80,995	£2.08	£168,469.60	16446	sí	£0.00
541431	18/01/2011 10:01	MEDIUM CERAMIC TOP STORAGE JAR	74,215	£1.04	£77,183.60	12346	sí	£0.00
C541433	18/01/2011 10:17	MEDIUM CERAMIC TOP STORAGE JAR	−74,215	£1.04	−£77,183.60	12346	sí	£0.00
556444	10/06/2011 15:28	PICNIC BASKET WICKER 60 PIECES	60	£649.50	£38,970.00	15098	sí	£649.50
C556445	10/06/2011 15:31	Manual	−1	£38,970.00	−£38,970.00	15098	sí	£649.50

- **80 995 PAPER CRAFT, LITTLE BIRDIE** (cliente 16446, 9 de diciembre). A las 9:15 se registra una venta de £168 470, la línea más grande del archivo, y doce minutos después la factura C581484 la cancela completa. Ese cliente sólo había comprado un par de cepillos de £1 en mayo, así que todo apunta a un error de captura.
- **74 215 MEDIUM CERAMIC TOP STORAGE JAR** (cliente 12346, 18 de enero). El mismo patrón: la venta a las 10:01 y la cancelación a las 10:17. Es la única compra que ese cliente tiene en todo el archivo, así que termina con monto neto cero (es uno de los casos con $M \leq 0$ de la Parte 6).

- **PICNIC BASKET WICKER 60 PIECES** (cliente 15098, 10 de junio). Se capturaron 60 unidades de un paquete que ya trae 60 canastas, a £649.50 cada una. Tres minutos después, una línea Manual de £38 970 cancela exactamente ese monto, y enseguida se factura 1 paquete a £649.50, que fue la venta real.

¿La limpieza las resuelve? No: las seis líneas sobreviven, porque ninguna regla las toca (son productos o ajustes Manual, con precio positivo). Quitarlas con una regla especial habría sido tomar decisiones a mano sobre casos individuales.

¿Las resuelve netear por día? Sí, las tres. En cada par la venta y su anulación ocurren el mismo día, así que la suma diaria las cancela: los dos primeros pares dejan neto cero y el de las canastas deja los £649.50 de la venta real. Esto funciona porque se decidió conservar las líneas `M`. Además, el par más grande cae el 9 de diciembre, que se descarta por estar incompleto (Parte 2). Donde netear por día no alcanza es en la Parte 6: el cliente 12346 cuenta una factura de venta en su frecuencia aunque no haya comprado nada de verdad.

4.5. La función `limpiar` (1.5)

Toda la limpieza está en `src/limpieza.py`, en la función `limpiar(df)`. Recibe el DataFrame crudo y devuelve el limpio, con una columna `Monto` = `Quantity` × `UnitPrice`. Las reglas están definidas una sola vez, en una lista ordenada, y la misma función arma la bitácora si se le pide. Así la bitácora no se puede desfasar de lo que de verdad hace la limpieza. Los scripts de las Partes 2 a 6 la importan, y el proyecto la puede reusar tal cual.

5. Parte 2: El calendario

5.1. La serie diaria (2.1)

La venta neta diaria es la suma de `Monto` de todas las líneas limpias de cada día, cancelaciones incluidas. Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011, contando ambos, hay 374 días calendario. En 305 hubo al menos una transacción, así que faltan 69. La figura 3 pone la serie sobre el calendario: una columna por semana y una fila por día de la semana.

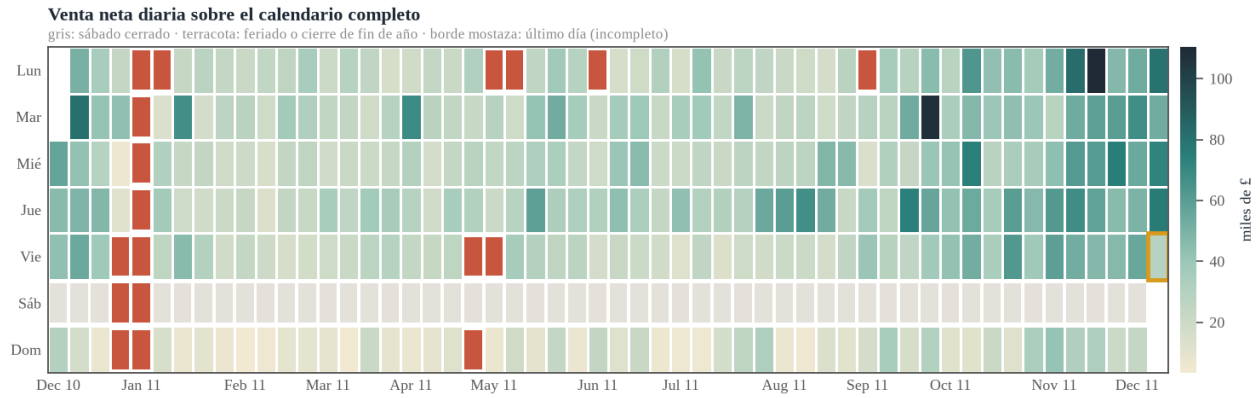


Figura 3: Venta neta diaria sobre el calendario. Cada cuadro es un día; la fila de los sábados está completamente cerrada.

5.2. Los días sin transacciones (2.2)

La tienda **no abre los sábados**: los 53 sábados del periodo están vacíos y no hay ni un sábado con ventas. Los otros 16 días cerrados (más dos sábados que coinciden con fiestas) se clasificaron contra el calendario oficial de bank holidays de Inglaterra y Gales de 2011 en la Tabla 8.

Hay tres grupos. El primero es el **cierre de fin de año**, del 24 de diciembre al 3 de enero: incluye los días sustitutos de Navidad, Boxing Day y Año Nuevo (los tres cayeron en fin de semana en 2010–2011, así que el feriado se corrió al lunes o martes siguiente) y además la tienda no abrió los días hábiles intermedios. El segundo son los **bank holidays** normales: Viernes Santo, Lunes de Pascua y los tres lunes de mayo y agosto. El tercero es el que no se repite: el **viernes 29 de abril de 2011**, feriado nacional por la boda real del príncipe Guillermo. Todo cierre queda explicado; no hay ningún día faltante sin razón.

¿Cuáles son móviles? Los que dependen de la Pascua: el Viernes Santo, el Domingo de Pascua (que no es bank holiday, pero la tienda no abrió ese domingo) y el Lunes de Pascua. En 2011 cayeron del 22 al 25 de abril; en 2012 caen del 6 al 9. Por eso FPP2 dice que son de lo más difícil de modelar: un indicador de "abril" o de "semana 16" no los captura. Los tres bank holidays de mayo y agosto cambian de fecha, pero siempre caen en lunes, así que no confunden el patrón semanal. La boda real ni siquiera es móvil: es única, y ningún modelo la puede aprender de la historia.

5.3. ¿Cero o faltante? (2.3)

Depende de para qué se use la serie. Un día cerrado es **cero** cuando la pregunta es contable: por ejemplo, la venta total de abril, el flujo de caja de una semana o la media móvil de la Parte 3, que

Tabla 8: Días sin transacciones que no se explican sólo por ser sábado.

Fecha	Día	Clasificación	¿Móvil?
24/12/2010	Viernes	Cierre de fin de año	no
25/12/2010	Sábado	Cierre de fin de año	no
26/12/2010	Domingo	Cierre de fin de año	no
27/12/2010	Lunes	Navidad (día sustituto)	no
28/12/2010	Martes	Boxing Day (día sustituto)	no
29/12/2010	Miércoles	Cierre de fin de año	no
30/12/2010	Jueves	Cierre de fin de año	no
31/12/2010	Viernes	Cierre de fin de año	no
01/01/2011	Sábado	Cierre de fin de año	no
02/01/2011	Domingo	Cierre de fin de año	no
03/01/2011	Lunes	Año Nuevo (día sustituto)	no
22/04/2011	Viernes	Viernes Santo	sí
24/04/2011	Domingo	Domingo de Pascua (no es bank holiday)	sí
25/04/2011	Lunes	Lunes de Pascua	sí
29/04/2011	Viernes	Boda real (solo en 2011)	no
02/05/2011	Lunes	Early May bank holiday	no
30/05/2011	Lunes	Spring bank holiday	no
29/08/2011	Lunes	Summer bank holiday	no

debe repartir la venta de una semana entre sus siete días. Ese día de verdad entraron cero libras. En cambio, es **faltante** cuando la pregunta es sobre el comportamiento de la demanda en los días que se puede vender. Por ejemplo, para estimar la venta promedio de un lunes, para calcular la ACF o para ajustar un modelo, un día cerrado no es una observación del proceso: nadie pudo comprar. Si se trata como cero, el modelo ve una caída de demanda que no existió, y además la ACF se llena de ceros que producen una correlación artificial cada siete días.

5.4. El último día (2.4)

El 9 de diciembre de 2011 **no está completo**. La última factura es de las 12:50, cuando la mediana de la hora de la última factura en el resto de los días es 17:24. Ese día suma £29,306, frente a un promedio de £49,599 en los ocho viernes anteriores, y además contiene el par de 80 995 unidades de la sección 4.4. Es el momento en que se extrajeron los datos, no el cierre del día. Por eso **se descarta**: tomarlo como un viernes normal metería una caída falsa justo al final de la serie, que es lo que más pesa en un pronóstico.

De aquí en adelante, la serie de trabajo es la diaria sobre el calendario completo, con los días cerrados como faltantes y sin el 9 de diciembre.

6. Parte 3: Tendencia, estacionalidad y autocorrelación

6.1. Tendencia (3.1)

La tendencia se estima con una media móvil centrada de 7 días sobre el calendario completo, con los días cerrados como cero (figura 4).

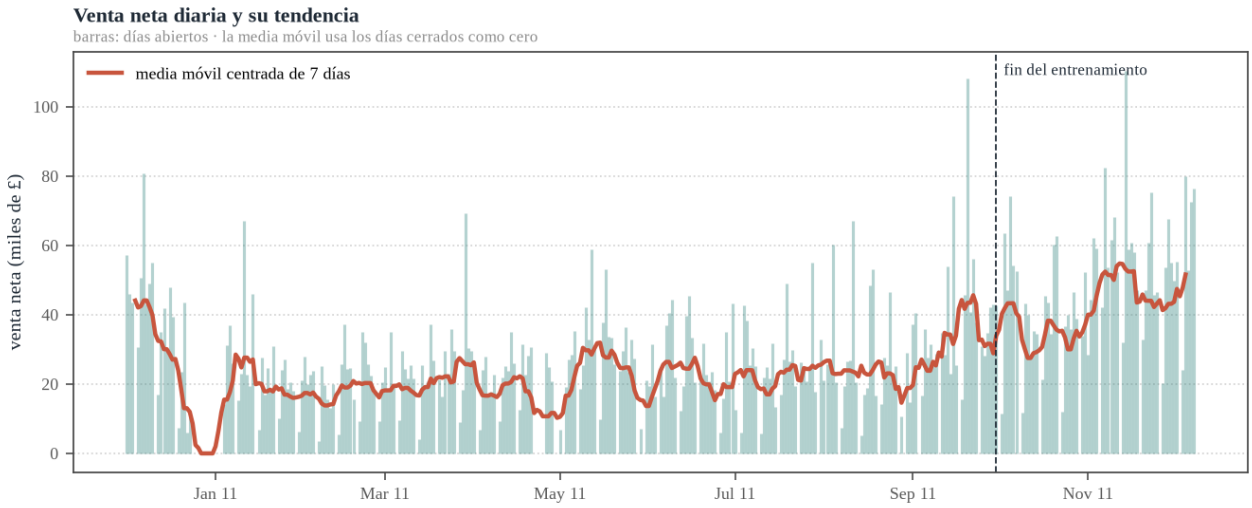


Figura 4: Venta neta de los días abiertos (barras) y media móvil centrada de 7 días (línea).

¿Por qué 7?

Porque el patrón semanal se repite cada 7 días, y una ventana de exactamente 7 días contiene una semana completa: cada día de la semana entra una sola vez, así que el patrón semanal se cancela y lo que queda es el nivel. Con 5 días la ventana contiene sólo parte de la semana, y según dónde caiga incluye o no al sábado cerrado y al domingo flojo: la "tendencia" subiría y bajaría con el patrón semanal. Con 30 días el patrón se cancela casi por completo, pero se borran cambios de nivel reales de pocas semanas, como la caída de Navidad o el arranque de septiembre. Además, 30 no es múltiplo de 7, así que cada ventana tiene un número distinto de cada día de la semana.

¿Por qué centrada?

Para que el valor en t represente el nivel alrededor de t: usa tres días antes, el propio día y tres días después. Una media móvil hacia atrás describe el nivel de hace tres días y llega tarde a cada cambio. Para describir la serie eso no conviene, aunque, como se va a ver en la Parte 5, para pronosticar es justo lo que no se puede usar.

La tendencia

Arranca alta en diciembre de 2010, se desploma a cero con el cierre de fin de año y entre enero y agosto se mantiene bastante estable, con un promedio de £20,808 diarios. A partir de septiembre sube con claridad y en noviembre promedia £47,057, con un máximo de £54,795: es la temporada en que los mayoristas se abastecen para Navidad. La consecuencia para el resto de la tarea es que el periodo de prueba, de octubre a diciembre, está en un nivel que el entrenamiento casi no conoce.

6.2. Estacionalidad (3.2)

Con el entrenamiento, para cada día abierto se calcula el cociente y_t/MA_t y el índice de cada día de la semana es el promedio de esos cocientes (Tabla 9 y figura 5).

Tabla 9: Índice estacional por día de la semana (entrenamiento).

Día	Índice	Días promediados
Lunes	1.164	37
Martes	1.545	42
Miércoles	1.232	42
Jueves	1.563	42
Viernes	1.118	39
Domingo	0.580	40
Promedio	1.200	

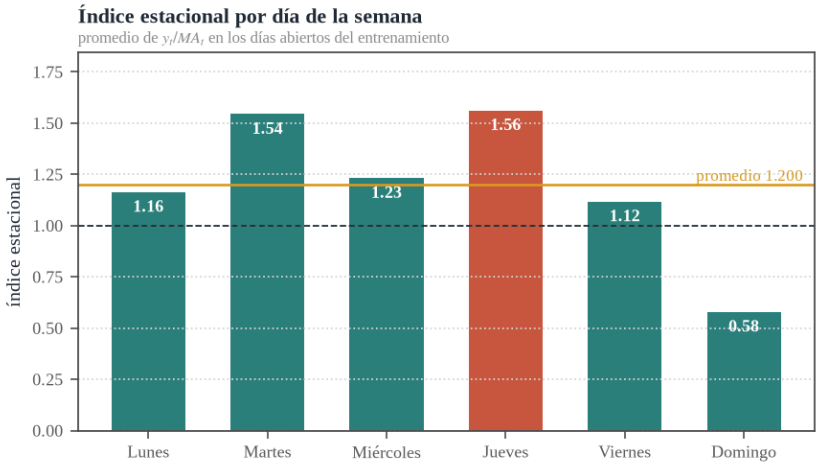


Figura 5: Índices estacionales. La línea punteada es 1 y la línea mostaza es el promedio de los seis índices.

Los días que más venden son el **jueves** y el **martes**, alrededor de un 55 % por encima del nivel de la semana. El **domingo** es por mucho el día más flojo: vende poco más de la mitad del nivel. Tiene sentido para una tienda que le vende sobre todo a negocios, que hacen sus pedidos en días hábiles.

¿Por qué el promedio no es 1? Porque la media móvil reparte la venta de la semana entre 7 días, y uno de ellos (el sábado) siempre vale cero. Si la venta de una semana es V, la media móvil es aproximadamente $V/7$, y los seis días abiertos venden en promedio $V/6$, así que su índice promedio tiende a $7/6 \approx 1.167$. Si se incluyera el sábado con índice cero, los siete índices sí promediarían cerca de 1. Sale un poco más, 1.200, porque las semanas con feriados tienen todavía más ceros en la ventana y eso infla los cocientes de los días abiertos de esas semanas.

6.3. Autocorrelación (3.3)

Se usa la misma función r_k de la Parte 0, ahora sobre los 245 días abiertos del entrenamiento, una fila por día y sin calendario (figura 6).

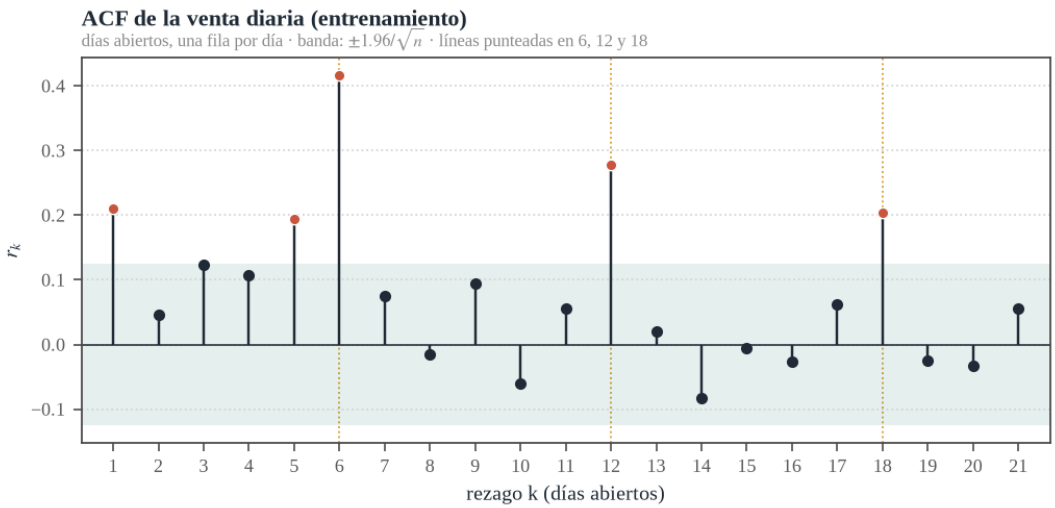


Figura 6: ACF de la venta en los días abiertos del entrenamiento. La banda es $\pm 1.96/\sqrt{245} = \pm 0.125$.

(a)

Se salen de la banda 5 de los 21 rezagos: el 1, el 5, el 6, el 12 y el 18. La serie **no pasa** la prueba de retardo 1 de la Tarea 2: $r_1 = 0.210$ es casi el doble de la banda. El pico está en el **rezago 6** ($r_6 = 0.416$), y se repite en 12 y 18. Seis filas de días abiertos son, casi siempre, **7 días calendario**: una semana completa, porque el sábado no tiene fila. Eso pasa en el 88 % de los casos; en el resto hay un feriado de por medio y la distancia es de 8 días o más. Ljung–Box lo confirma sin ambigüedad: $Q(6) = 71.4$ ($p = 2.1 \times 10^{-13}$) y $Q(12) = 96.9$ ($p = 2.2 \times 10^{-15}$).

(b)

La ACF mezcla las dos razones de la Parte 0. Los picos en 6, 12 y 18 se ven igual que el patrón semanal simulado en 0.4: es la media que cambia según el día de la semana, no memoria. Los valores positivos en los rezagos 1 al 5, que no caen rápido a cero, se parecen más a la tendencia simulada. Eso es consistente con el cambio de nivel que se vio en 3.1, pero también podría ser memoria genuina. Con esta gráfica no se puede separar una cosa de la otra; para eso hay que quitar primero la estacionalidad, que es lo que hace la Parte 4.

7. Parte 4: Del AR(1) al SARIMA

Toda esta parte trabaja con los 245 días abiertos del entrenamiento como una fila por día.

7.1. Indicadoras de día de la semana (4.1)

Se ajustó por OLS la venta contra seis variables indicadoras, una por día abierto, sin intercepto. Cada coeficiente es simplemente la venta promedio de ese día, y el residuo e_t es cuánto se aleja cada día del promedio de su día de la semana. La figura 7 muestra la ACF de e_t (panel superior izquierdo) junto con las de los modelos siguientes, y la Tabla 10 reúne las pruebas de Ljung–Box de toda la parte.

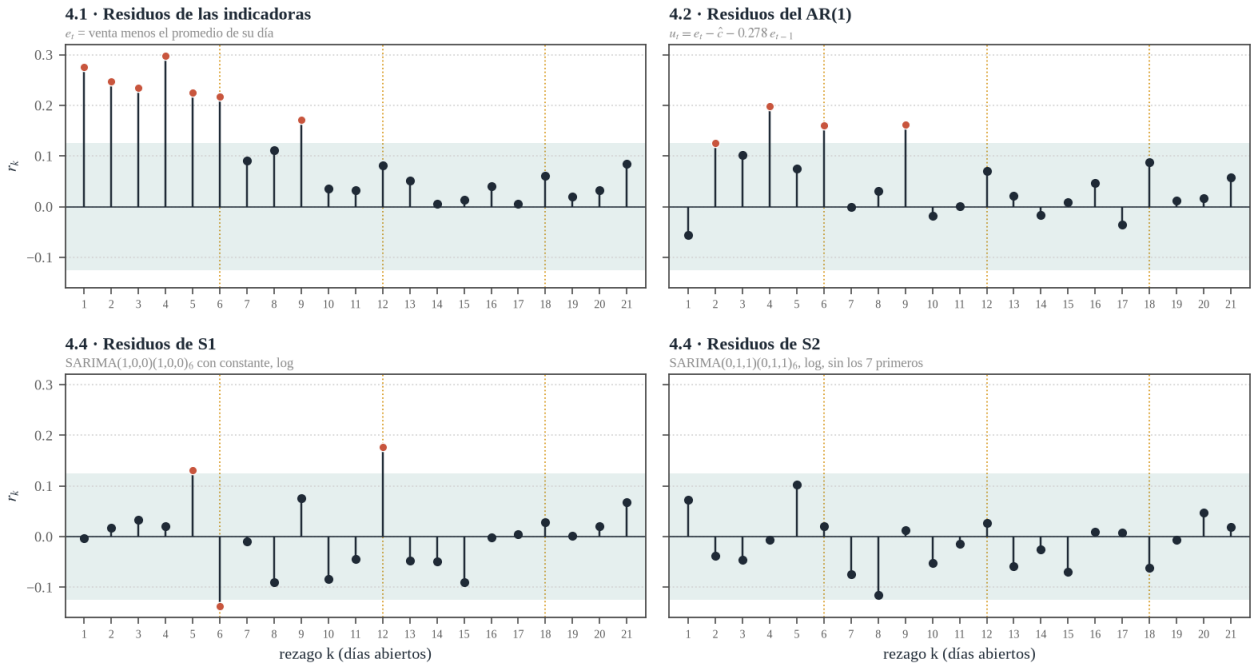


Figura 7: ACF de los residuos de los cuatro modelos de la Parte 4. Las líneas punteadas marcan los rezagos 6, 12 y 18.

Tabla 10: Ljung–Box sobre los residuos de cada modelo. La última columna son los grados de libertad usados para $Q(6)$ y $Q(12)$.

Residuos	$Q(6)$	valor-p	$Q(12)$	valor-p	g. l.
Indicadoras (e_t)	95.2	2.5×10^{-18}	110.3	5.2×10^{-18}	6 / 12
AR(1) sobre e_t (u_t)	25.1	1.4×10^{-4}	33.4	4.5×10^{-4}	5 / 11
S1	9.57	0.048	23.54	0.009	4 / 10
S2	4.88	0.300	10.49	0.398	4 / 10

El pico estacional prácticamente desapareció: r_{12} bajó de 0.277 a 0.081 y el patrón de 6, 12, 18 ya no domina. Pero quedó otra cosa: los rezagos 1 a 6 están todos entre 0.2 y 0.3 y bajan muy despacio. Si fuera un AR(1) con $\phi \approx 0.276$, la ACF tendría que caer como ϕ^k: 0.28, 0.08, 0.02…, y no es eso lo que se ve. La forma se parece mucho más a la del proceso con tendencia de la Parte 0: una ACF casi plana. Al modelo le falta **el nivel que cambia**. Las indicadoras suponen que el lunes promedio

es el mismo en enero que en septiembre, y los residuos heredan todo el movimiento de la tendencia: semanas enteras quedan por encima o por debajo de su promedio.

7.2. AR(1) sobre los residuos (4.2)

El OLS de e_t contra e_{t-1} da $\hat{\phi} = 0.278$. Con sus residuos, $u_t = e_t - \hat{c} - \hat{\phi}\, e_{t-1}$, la ACF baja (panel superior derecho), pero **todavía no parece ruido blanco**: siguen fuera de la banda los rezagos 2, 4, 6, 9. Ljung–Box, con un grado de libertad menos por haber estimado ϕ, rechaza con claridad tanto con $m = 6$ como con $m = 12$.

No alcanzó un AR(1). Un AR(1) modela una memoria que se olvida geométricamente, y lo que había en e_t era en gran parte un nivel que se mueve despacio. Un solo rezago no puede reproducir una ACF casi plana, y de paso la correlación en el rezago 6 sigue ahí, porque el patrón semanal tampoco es exactamente constante.

7.3. SARIMA (4.3)

Lo anterior motiva modelos que combinen memoria de corto plazo, memoria estacional y, si hace falta, diferencias para seguir un nivel que se mueve. Con `SARIMAX` de statsmodels se ajustaron dos modelos sobre el logaritmo de la venta, pasando el arreglo de valores sin fechas (porque las fechas tienen huecos):

- **S1**: SARIMA$(1,0,0)(1,0,0)_6$ con constante. Es un AR(1) más un AR estacional: hoy depende de ayer y del mismo día de la semana pasada. Es estacionario.
- **S2**: SARIMA$(0,1,1)(0,1,1)_6$ sin constante, el modelo de aerolínea. Diferencia una vez y diferencia estacionalmente una vez, y corrige con los errores recientes. No es estacionario.

¿Por qué $s = 6$ y no 7?

Porque el modelo no ve fechas, ve filas, y en las filas de días abiertos una semana tiene 6 días: el sábado no existe. El mismo día de la semana pasada está 6 filas atrás, que es justo el pico que se vio en 3.3. La suposición **se rompe en las semanas con feriado**: si un lunes cierra, esa semana tiene 5 filas y, durante las siguientes, "6 filas atrás" ya no es el mismo día de la semana sino el anterior. En estos datos eso pasa en la Pascua, la boda real, los bank holidays de lunes y, sobre todo, en las dos semanas del cierre de fin de año (en total, en el 12 % de los saltos de 6 filas medidos en 3.3).

¿Por qué el logaritmo?

Porque la variación de la serie crece con su nivel: en el otoño, cuando la venta es más alta, las diferencias entre días también son más grandes. FPP2 recomienda transformar justo en ese caso. En logaritmo, un efecto multiplicativo como "el jueves vende 55 % más" se vuelve aditivo, que es lo que suponen los modelos ARIMA, y la varianza se estabiliza. Además, todos los días abiertos tienen venta neta positiva, así que el logaritmo existe.

Convergencia

La Tabla 11 compara el ajuste con las 50 iteraciones por defecto y con 500.

S2 converge en 14 iteraciones y da lo mismo con cualquier límite. S1, en cambio, **no converge** con el límite por defecto, y lo que devuelve en ese caso es engañoso: el AR estacional queda en 0.895 y la constante en 0.937. Con 500 iteraciones converge en 81, y el AR estacional baja a 0.521 mientras la

Tabla 11: Convergencia del optimizador. Los parámetros de S1 son (intercept, ar.L1, ar.S.L6, sigma2) y los de S2 son (ma.L1, ma.S.L6, sigma2).

Modelo	`maxiter`	¿Convergió?	Iteraciones	Parámetros
S1	50 (defecto)	no	50	$0.937, 0.105, 0.895, 0.236$
S1	500	sí	81	$4.212, 0.132, 0.521, 0.216$
S2	50 (defecto)	sí	14	$-0.914, -0.670, 0.213$
S2	500	sí	14	$-0.914, -0.670, 0.213$

constante sube a 4.212. Los dos juegos de parámetros dan una media parecida: en un AR la media es la constante dividida entre $(1-\phi)(1-\Phi)$, así que el optimizador puede subir Φ y bajar la constante casi sin cambiar el ajuste. Por eso le cuesta encontrar el óptimo. Un Φ de 0.9 implicaría una memoria estacional mucho más larga de la que hay. En lo que sigue se usa siempre la versión que convergió.

7.4. Diagnóstico (4.4)

Los paneles inferiores de la figura 7 y las dos últimas filas de la Tabla 10 muestran los residuos de los dos SARIMA, con $m-2$ grados de libertad porque cada modelo estima dos coeficientes ARMA. Para S2 se descartan los primeros 7 residuos, que son artefactos del arranque de las diferencias.

S2 deja residuos de ruido blanco y S1 no. En S2 ningún rezago se sale de la banda y Ljung–Box no rechaza ($p = 0.30$ y $p = 0.40$). En S1 se salen los rezagos 5, 6 y 12, y Ljung–Box rechaza al 5 % con ambos m. El patrón es el mismo que en 4.1: lo que S1 no captura es el nivel que se mueve, y las diferencias de S2 son justamente la herramienta para eso.

7.5. ¿Hacia dónde van los pronósticos? (4.5)

S1 es estacionario, así que se comporta como el AR(1) de la Parte 0: el efecto de lo último observado se olvida geométricamente. A medida que el horizonte crece, sus pronósticos **regresan a la media del proceso**, que en libras es $\exp(c/((1-\phi)(1-\Phi))) \approx$ £24,878, y el patrón semanal se va apagando como Φ^k. S2 se parece a la caminata aleatoria: nunca olvida. Sus pronósticos **no regresan a nada**: arrancan del último nivel observado, repiten el patrón semanal reciente y, como tiene una diferencia normal y una estacional, prolongan además la pendiente local que traía la serie. Su incertidumbre también crece sin límite con el horizonte, igual que $\mathrm{Var}(Y_t) = t\sigma^2$.

La figura 8 lo muestra con los dos modelos ajustados con todo el entrenamiento. S1 se aplana enseguida en unas £24,878, el nivel de enero a agosto, mientras que S2 sigue la subida de septiembre. Esto ya anticipa qué va a pasar en la Parte 5, cuando la venta de octubre a diciembre esté muy por encima del nivel histórico.

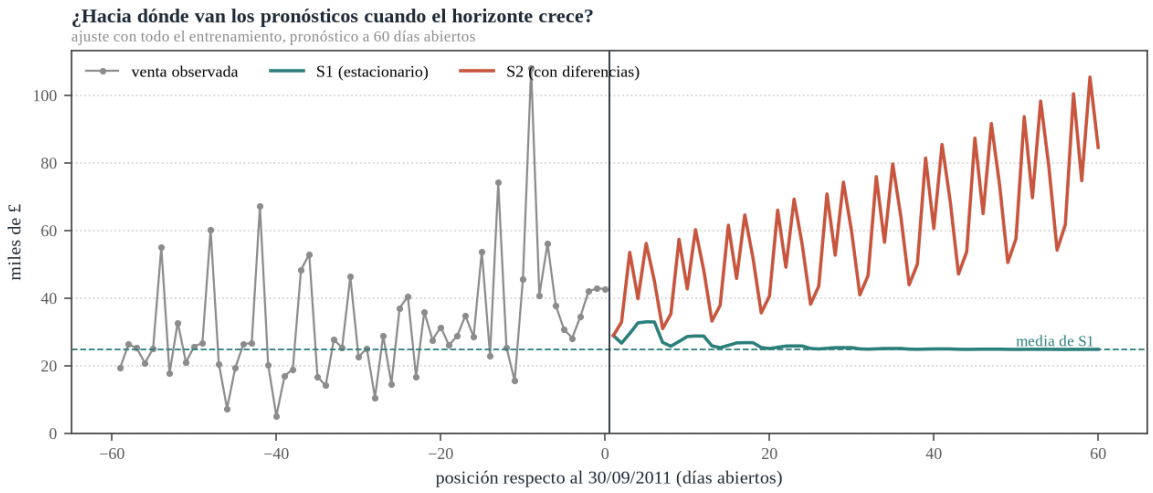


Figura 8: Pronósticos a 60 días abiertos desde el 30 de septiembre.

8. Parte 5: Pronóstico y fuga

El pronóstico se hace como en la vida real: cada domingo, con todo lo observado hasta ese día (incluida la venta del domingo), se pronostican los días abiertos de lunes a domingo siguientes. Después se avanza una semana, se reajusta y se repite.

8.1. Los seis modelos (5.1)

Además de S1 y S2 se implementaron:

- **B1**: la media histórica de los días abiertos.
- **B2**: el naive estacional, que pronostica el valor del mismo día de la semana abierto más reciente.
- **M1**: OLS con una tendencia lineal en t (días desde el 1 de diciembre de 2010) más las seis indicadoras.
- **M2**: OLS con las seis indicadoras y dos rezagos, y_{t-7} y y_{t-14}. Si alguno cae en un día cerrado, se usa el mismo día de la semana abierto más reciente; en la práctica, y_{t-7} es el último día abierto con el mismo día de la semana e y_{t-14} el anterior a ése. Se comprobó con el ejemplo del enunciado: para el 9 de mayo, y_{t-7} vale £31,435.26, que es la venta del 18 de abril. Las filas sin rezago al inicio de la serie no se usan para ajustar.

Para S1 y S2, el horizonte de cada objetivo es su posición entre los días abiertos posteriores al origen. Se usó la configuración que convergió en 4.3 y se verificó `mle_retvals['converged']` en cada reajuste: S1 convergió en 32 de 32 orígenes y S2 en 32 de 32.

¿Por qué M2 puede usar y_{t-7} y no y_{t-1}? Desde un domingo, el día más lejano que se pronostica es el domingo siguiente, siete días después. Para cualquier objetivo de esa semana, $t-7$ cae en el origen o antes, así que y_{t-7} ya se observó. Con y_{t-1} sólo se podría pronosticar el lunes: para el martes haría falta la venta del lunes, que todavía no ocurrió. M2 es un modelo de un paso que no sabe pronosticar sus propios predictores.

¿Cómo usa S1 el rezago 1? De forma recursiva. Para el lunes usa el domingo observado; para el martes usa *su propio pronóstico* del lunes en lugar del valor real, y así sucesivamente. El modelo especifica cómo se genera toda la serie, así que puede pronosticar sus propios rezagos, y el filtro de Kalman de statsmodels lo hace automáticamente. El precio es que el error se acumula con el horizonte.

8.2. Tres formas de estimar el error (5.2)

La Tabla 12 reúne el MAE y el RMSE de los seis modelos estimados de tres formas:

(a) validación cruzada aleatoria de 5 folds sobre el entrenamiento, repetida con 10 semillas (141903 a 141912); se reporta la media y la desviación estándar entre semillas;

(b) origen móvil semanal dentro del entrenamiento, con los 22 domingos de mayo a septiembre como orígenes y 128 días evaluados;

(c) el periodo de prueba con origen móvil semanal: 10 orígenes, del 2 de octubre al 4 de diciembre, y los 58 días abiertos del 3 de octubre al 8 de diciembre.

En los tres casos el MAE y el RMSE se calculan juntando todos los días pronosticados.

Tabla 12: MAE y RMSE en libras. (a) y (b) son dentro del entrenamiento. En (a), media ± desviación estándar entre las 10 semillas.

	(a) CV aleatoria		(b) Origen móvil		(c) Prueba	
Modelo	MAE	RMSE	MAE	RMSE	MAE	RMSE
B1	$10{,}251 \pm 42$	$14{,}235 \pm 43$	10,254	14,936	22,472	27,061
B2	—		11,341	15,652	14,409	18,637
M1	$9{,}150 \pm 117$	$12{,}555 \pm 115$	9,832	13,901	15,202	20,283
M2	$8{,}318 \pm 60$	$11{,}754 \pm 76$	9,277	13,434	15,153	19,846
S1	—		9,657	13,768	16,739	21,052
S2	—		10,057	14,027	12,545	15,901
M2 + MA (5.4)	$7{,}475 \pm 72$	$10{,}083 \pm 85$	8,386	11,373	sólo con trampa	

¿Por qué (a) no tiene sentido para B2, S1 y S2?

Porque los tres dependen del orden. B2 pronostica con "el valor más reciente del mismo día", y en un fold aleatorio lo más reciente puede ser un día posterior al que se pronostica. S1 y S2 necesitan la serie como una secuencia contigua para calcular sus rezagos y diferencias; si se le quitan días al azar, la fila anterior ya no es el día anterior, y no queda claro ni qué se está ajustando. En general, la validación cruzada aleatoria usa el futuro para pronosticar el pasado, que es justo lo que en series de tiempo no se puede hacer.

¿Cuál se acerca más a (c)?

La (b). Para los tres modelos que tienen las tres estimaciones, (a) da el error más bajo, (b) uno un poco más alto y (c) el más alto de todos: para M2, 8,318, 9,277 y 15,153. La validación aleatoria es optimista porque cada día de prueba tiene vecinos de ambos lados en el entrenamiento. Pero **ninguna se acerca de verdad**: en prueba, el MAE es entre 1.25 y 1.7 veces lo que prometía (b), y para B1 más del doble. El ranking de los modelos también cambia: en (b) gana M2 y S2 queda en medio de la tabla; en (c) S2 es el mejor.

8.3. ¿Qué modelo gana en prueba? (5.3)

Gana S2, con un MAE de £12,545, seguido de B2 (£14,409). La figura 9 muestra por qué.

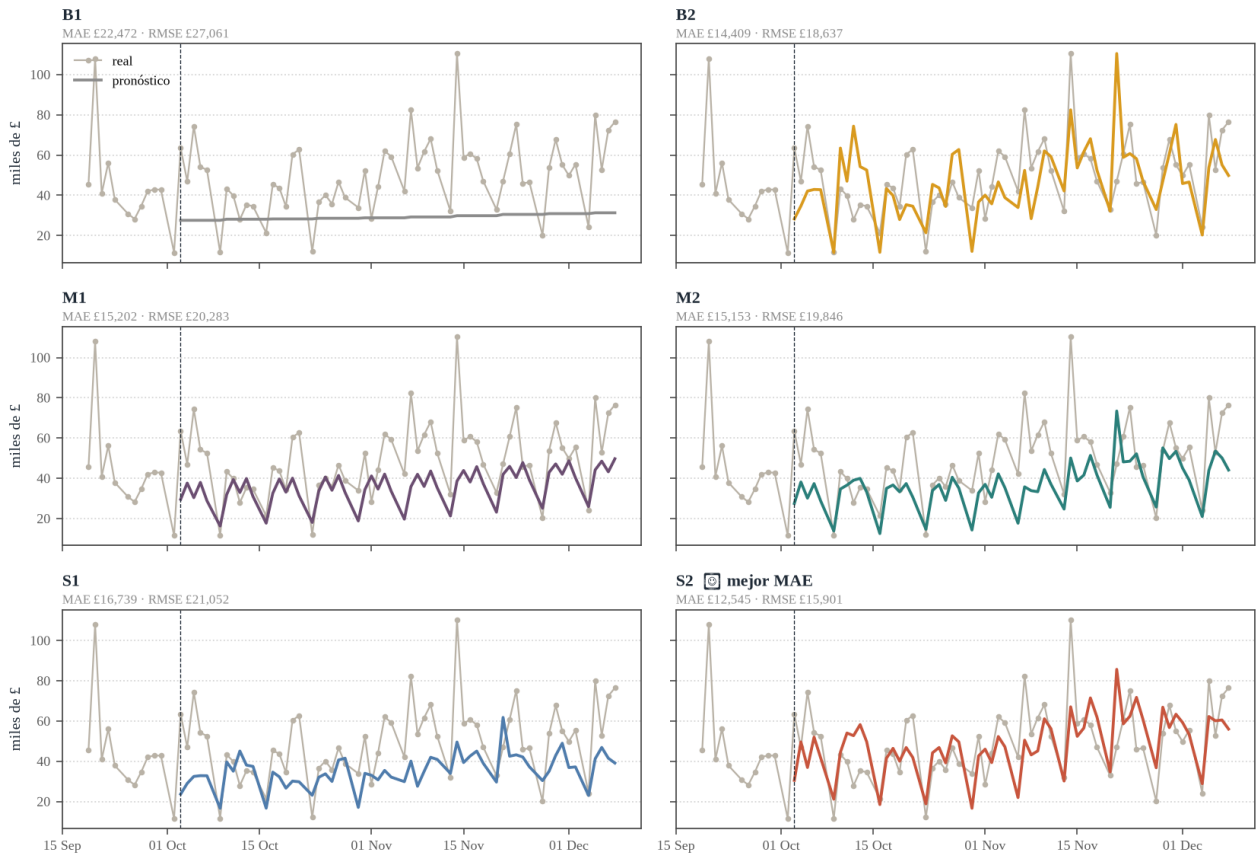


Figura 9: Pronósticos semanales con origen móvil (en color) contra la venta real (en gris) en el periodo de prueba. La línea punteada marca el 3 de octubre.

En el periodo de prueba la venta promedio por día abierto fue de £49,768, contra £27,632 en el entrenamiento. Los modelos que están anclados a la historia completa se quedan abajo todo el periodo: B1 pronostica una línea casi plana alrededor de la media histórica, S1 regresa a su media de unas £24,878 (como se anticipó en 4.5), y M1 y M2 suben un poco con la tendencia y los rezagos, pero se quedan cortos. Los dos modelos que mejor siguen la subida son los que arrancan cada semana del nivel más reciente: B2, que repite la semana anterior, y S2, que además la suaviza. B2 copia todo, incluido el ruido: un día atípico se repite la semana siguiente (se ve a fines de noviembre, cuando repite el pico de la semana anterior). S2, en cambio, promedia el pasado reciente a través de sus términos MA, así que se mueve con el nivel sin copiar cada sobresalto. Eso coincide con el diagnóstico de 4.4: S2 era el único modelo cuyos residuos parecían ruido blanco, o sea, el único que había capturado la estructura completa de la serie, incluido el nivel que cambia.

8.4. La trampa (5.4)

Un compañero propone agregarle a M2 la media móvil centrada de 7 días de la Parte 3 como predictor. Con la media móvil calculada una sola vez sobre toda la serie, el resultado está en la última fila de la Tabla 12: en (a) el MAE baja de 8,318 a 7,475 y en (b) de 9,277 a 8,386. Se ve mejor que cualquier otro modelo.

Por qué es ilegal. La media móvil centrada en t promedia $y_{t-3}, \ldots, y_{t+3}$. Incluye la venta del propio día que se quiere pronosticar y tres días del futuro. En la vida real, el domingo en que se hace el pronóstico nadie conoce esos valores. El modelo no aprendió a pronosticar: aprendió a leer una versión suavizada de la respuesta.

Por qué el origen móvil no lo detecta. El origen móvil respeta el tiempo en las *filas*: sólo ajusta con días anteriores al origen. Pero la columna de la media móvil se calculó una vez, con toda la serie, antes de partir nada. Cuando el procedimiento lee el predictor de un día objetivo, ese número ya contiene la venta de ese día y de los tres siguientes. La fuga está en la construcción de la variable, no en la partición, y ninguna partición la puede ver.

Por qué (c) no se puede calcular sin trampa. Para pronosticar el jueves 8 de diciembre con este modelo hace falta la media móvil de ese día, que necesita las ventas del 5 al 11 de diciembre: el valor que se quiere pronosticar y días que ni siquiera están en los datos. Para cualquier día de prueba, calcular el predictor exige usar justo los datos de prueba que se supone que no se conocen. Lo único honesto sería sustituirla por una media móvil hacia atrás, que ya es otro modelo.

8.5. ¿Por qué todo se queda corto? (5.5)

Hay dos causas distintas.

La primera viene de **cómo se partieron los datos**. La validación cruzada aleatoria mezcla pasado y futuro: cada día de prueba tiene vecinos de ambos lados en el entrenamiento, y los modelos con rezagos (como M2) ven en el entrenamiento días posteriores a los que pronostican. Por eso (a) es el más optimista. Esta causa **sí se arregla** con una mejor validación: el origen móvil reproduce exactamente las condiciones del pronóstico real, y por eso (b) da errores más grandes que (a).

La segunda es que **la serie cambió**. De octubre a diciembre la tienda vendió casi el doble por día que en el resto del año, y con el nivel crecen también los errores. Cualquier validación hecha dentro del entrenamiento mide el error en un régimen de enero a septiembre que ya no es el de la prueba. Esta causa **no se arregla** con una mejor validación: el origen móvil (b) también se quedó corto, porque no hay ninguna forma de medir dentro del entrenamiento el error de un periodo que el entrenamiento nunca vio.

¿Se puede estimar la estacionalidad anual con un año de datos? No. Para estimar un efecto estacional hay que ver el mismo momento del ciclo varias veces y promediar. Con un solo año, cada mes aparece una vez (y diciembre, a medias, dos), así que no hay forma de separar "noviembre siempre es alto" de "la tienda está creciendo" o de "este noviembre fue especial". La estacionalidad anual y la tendencia quedan confundidas. Se necesitan al menos dos o tres años completos. Ésa es exactamente la parte de la serie que hizo fallar a todos los modelos en la prueba.

9. Parte 6: Detrás de la serie hay clientes: análisis RFM

9.1. R, F y M al 1 de octubre (6.1)

Con los datos limpios que tienen `CustomerID` y sólo las transacciones anteriores al 1 de octubre de 2011, para cada cliente se calculó:

- **R**: los días entre su última factura de venta y el 1 de octubre;
- **F**: el número de facturas de venta distintas (las cancelaciones no cuentan como compras);
- **M**: la venta neta total, cancelaciones incluidas.

Hay **3,615 clientes** con al menos una factura de venta antes del 1 de octubre. Otros 43 identificadores sólo tienen cancelaciones en ese periodo (devoluciones de compras anteriores a diciembre de 2010, que no están en el archivo). No tienen una compra a partir de la cual medir la recencia, así que no entran.

11 clientes tienen $M \leq 0$: devolvieron tanto o más de lo que compraron, como el cliente 12346 de la sección 4.4. Se dejan en el análisis, porque el enunciado pide puntuarlos junto con los demás. Su puntaje de monto queda en 1 de forma natural, que es lo correcto: en términos netos no le han dejado dinero a la tienda.

¿Por qué no usar nada posterior al 1 de octubre? Porque en 6.3 se va a medir qué tan bien RFM anticipa quién compra después de esa fecha. Si R, F o M incluyeran transacciones posteriores, un cliente que compró en noviembre tendría recencia corta *porque* compró en noviembre, y el análisis se estaría prediciendo a sí mismo. Es la misma fuga de la Parte 5.4, ahora con clientes en lugar de días.

9.2. Puntajes por quintiles (6.2)

Cada dimensión se convierte en un puntaje de 1 a 5 por quintiles, con 5 como lo mejor: la recencia más corta, la frecuencia más alta y el monto más alto.

El problema con F es que es un conteo con muchísimos empates: el 40.1 % de los clientes tiene $F = 1$. El primer quintil termina en $F = 1$, pero también el segundo, así que los bordes de los quintiles se repiten y `pd.qcut` directamente sobre F falla. No hay manera de partir a los clientes en cinco grupos del mismo tamaño usando sólo el valor de F.

Para que el resultado sea reproducible se siguió el procedimiento del enunciado: los clientes ordenados por `CustomerID`, barajados con `numpy.random.default_rng(2026).permutation`, y después `pd.qcut(F.rank(method='first'), 5)`. Se usó el mismo orden barajado para R y M, que también tienen empates (muchos clientes compraron por última vez el mismo día).

¿Qué implica para dos clientes con la misma F? Que pueden terminar con puntajes distintos sólo por suerte. Los clientes con $F = 1$ quedan repartidos entre los puntajes 1, 2 y 3 según el orden en que los dejó la permutación. Entre ellos, la diferencia de puntaje no significa nada: con otra semilla un cliente con puntaje 3 podría tener 1. El puntaje es reproducible, pero en los empates no es informativo, y conviene tenerlo en cuenta antes de tratar a un cliente con $F_s = 3$ como más valioso que otro con $F_s = 1$.

9.3. ¿Quién vuelve a comprar? (6.3)

Sea compra$_i$ = 1 si el cliente tiene al menos una factura de venta entre el 1 de octubre y el 8 de diciembre. Lo cumple el 50.8 % de los clientes. La Tabla 13 y la figura 10 muestran la fracción que compró para cada puntaje, y la Tabla 14 da el AUC de cada dimensión como clasificador de compra$_i$, con los valores crudos (R con el signo invertido, para que más alto sea mejor).

Tabla 13: Fracción que compró, por puntaje.

Puntaje	R	F	M
1	27.7 %	32.9 %	29.5 %
2	38.5 %	31.0 %	37.3 %
3	55.0 %	45.0 %	45.5 %
4	66.4 %	59.3 %	61.0 %
5	66.3 %	85.6 %	80.5 %

Tabla 14: AUC como clasificador de compra$_i$.

	$-$R	F	M	$R_s + F_s + M_s$
AUC	0.672	0.720	0.709	0.734

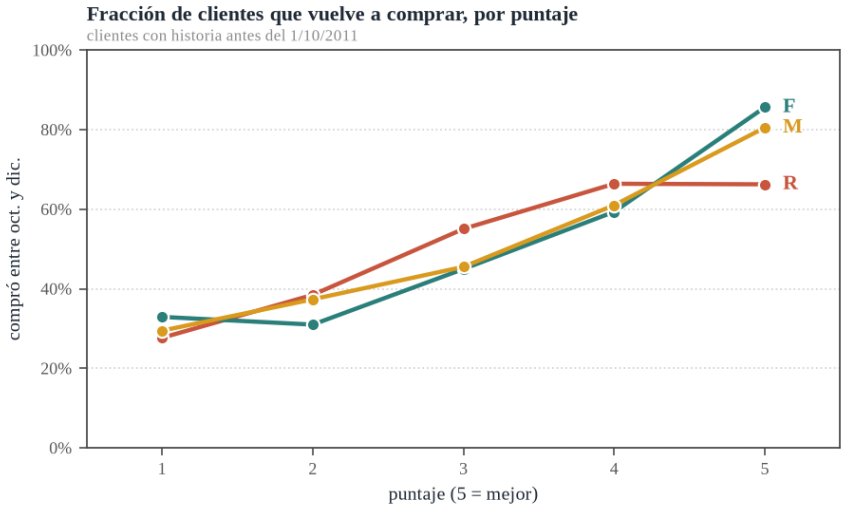


Figura 10: Fracción de clientes que volvió a comprar entre octubre y diciembre, para cada puntaje de R, F y M.

Las tres dimensiones separan en la dirección esperada: a mejor puntaje, más probable que el cliente vuelva. **F es la que mejor separa**: del puntaje 1 al 5 la tasa pasa de 33 % a 86 %, y tiene el AUC individual más alto (0.720). Lo plano entre los puntajes 1 y 2 de F es justamente el efecto del desempate al azar: los dos grupos son clientes con $F = 1$, así que en realidad no hay diferencia entre ellos. M queda muy cerca (0.709), lo cual es natural porque quien compra seguido acumula más monto. R es la más débil (0.672), y su curva se aplana arriba: los puntajes 4 y 5 compran en la misma proporción. Haber comprado hace dos semanas o hace dos meses importa poco para un mayorista que pide con cierta periodicidad. La suma de los tres puntajes le gana a cada uno por separado (0.734), pero por poco: las tres dimensiones están muy correlacionadas y se repiten bastante información.

9.4. Los campeones (6.4)

Los "campeones" son los clientes con puntaje 4 o 5 en las tres dimensiones. Son 777 clientes, el **21.5 %** del total, y generaron el **53.3 %** de la venta neta del 1 de octubre al 8 de diciembre de todos

los clientes con `CustomerID` (£2,400,689), incluidos los nuevos (figura 11). Es la concentración típica de este tipo de negocio: una quinta parte de los clientes hace más de la mitad de la venta.

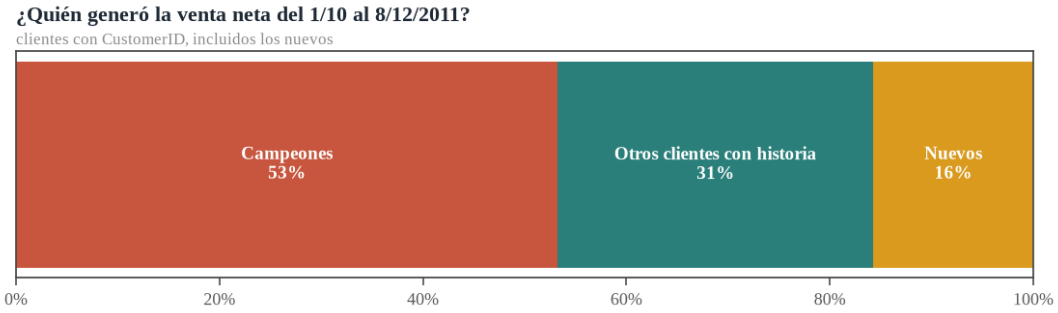


Figura 11: Reparto de la venta neta del 1 de octubre al 8 de diciembre entre campeones, el resto de los clientes con historia y los clientes nuevos.

9.5. Los clientes nuevos (6.5)

Los clientes nuevos, los que no tenían ninguna factura de venta antes del 1 de octubre, fueron 721 y generaron el **15.7 %** de la venta neta de octubre a diciembre de los clientes con `CustomerID`.

¿Puede RFM, o un modelo cliente por cliente, pronosticar esa venta? RFM no, y un modelo cliente por cliente tampoco, si sólo pronostica a los clientes que ya existen en la historia: un cliente nuevo no tiene R, ni F, ni M, ni fila en la tabla. Si se pronostica cada cliente histórico y se suma (*bottom-up*), ese 15.7 % no aparece en ningún lado, y el total queda sistemáticamente corto. Un *bottom-up* ampliado sí podría cubrirlo, pero sólo agregando un modelo aparte para la llegada de clientes nuevos (cuántos llegan y cuánto compran), que ya no se construye cliente por cliente. En cambio, la serie agregada de la Parte 5 (*top-down*) sí incluye a los clientes nuevos: no sabe quiénes son, pero su venta está dentro de cada día del total, así que la tendencia que siguieron B2 y S2 en otoño ya incluye a los clientes que llegaron en esa temporada.

Conexión con el proyecto. En el proyecto se va a comparar un pronóstico construido cliente por cliente contra uno sobre la serie agregada. Este resultado dice que el *bottom-up* parte con una desventaja estructural de alrededor de un 16 % en esta época del año, a menos que se le agregue un componente aparte para la llegada de clientes nuevos. A cambio, el enfoque por cliente sabe *quién* va a comprar, que el agregado no puede saber.

10. Conclusiones

- Una serie puede reprobar una prueba de independencia por memoria o por una media que cambia, y las dos cosas se ven distinto en la ACF: la memoria del AR(1) cae como ϕ^k, mientras que una tendencia deja una ACF casi plana y una estacionalidad deja picos en el periodo. La prueba de retardo 1 reprobó a una tendencia sin memoria y no detectó el patrón semanal en cerca del 89 % de las réplicas, el mismo punto ciego que dejó pasar a RANDU en la Tarea 2. Ljung–Box sólo lo arregla si m cubre el periodo estacional.
- El estimador OLS del AR(1) tiene un sesgo hacia abajo de orden $1/n$ que crece al acercarse a la raíz unitaria, y para la caminata aleatoria r_k no estima nada que exista.
- En los datos reales, la limpieza movió poco dinero en total, pero las decisiones importan: conservar las líneas Manual es lo que permite que la venta mal capturada de las canastas se cancele al netear por día. Las seis líneas más grandes del archivo resultaron ser tres errores corregidos el mismo día.
- El calendario explica todos los días faltantes: sábados, el cierre de fin de año, la Pascua, los bank holidays y la boda real. Al trabajar con filas de días abiertos, la semana mide 6 filas, y de ahí sale $s = 6$.
- La autocorrelación de la venta es una mezcla de estacionalidad semanal y de un nivel que se mueve. Quitar el día de la semana no basta, y un AR(1) tampoco; el modelo con diferencias S2 es el único que deja residuos de ruido blanco.
- S2 ganó en prueba, pero todas las estimaciones dentro del entrenamiento se quedaron cortas. Parte de eso se arregla validando con origen móvil en lugar de folds aleatorios; la otra parte, que la serie casi duplicó su nivel en la temporada navideña, no se puede arreglar con un año de datos. Un predictor que mira el futuro, como la media móvil centrada, hace que el modelo se vea mejor y ninguna partición lo detecta.
- Detrás de la serie, una quinta parte de los clientes hace más de la mitad de la venta, y los clientes nuevos aportan cerca de una sexta parte que el pronóstico agregado ve de forma natural y que uno cliente por cliente sólo puede cubrir si se le agrega un modelo de captación de clientes.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.

[5] Gobierno del Reino Unido. *UK bank holidays*. `https://www.gov.uk/bank-holidays`